FICHA DE IDENTIFICACIÓN DE TRABAJO DE INVESTIGACIÓN

Título	Arquitectura Predictiva Basada en Aprendizaje Supervisado, Edge Computing y XAI para la Optimización Comercial: Caso Delizia	
Autor/es	**Nombres y Apellidos**	**Código de estudiantes**
	Emilio Gabriel Fernández Jiménez	88078
Fecha	28/04/2026	

Carrera	Ing. De Sistemas
Asignatura	Redes Neuronales
Grupo	A
Docente	Ing. Roger Rolando Perez Rojas
Periodo Académico	I/2026
Subsede	Oruro

Copyright © (2026) por (Emilio Gabriel Fernández Jiménez). Todos los derechos reservados.

Tabla De Contenidos

Lista De Figuras 3
Introducción 4
Capítulo 1. Planteamiento del Problema 6
1.1 Formulación del Problema 6
1.2 Objetivos 6
1.3 Justificación 7
Capítulo 2. Marco Teórico 8
2.1 Área de Estudio/Campo de Investigación 8
2.2 Desarrollo del Marco Teórico 8
2.2.1 Fundamentos y Mecánica del Aprendizaje Supervisado 8
2.2.2 Modelado de Redes Neuronales y Calidad de Generalización 10
2.2.3 Optimización para Edge Computing y Redes Discretas 13
2.2.4 Interpretabilidad Algorítmica (XAI) en Entornos Comerciales 15
2.2.5 Interpretabilidad mediante Analogías con Redes Biológicas 18
Capítulo 3. Resultados y Discusión 20
3.1 Captura de Datos Sensoriales en el POS (Estímulos del Entorno) 20
3.2 Motor de Inferencia Binarizado (Procesamiento Sináptico Discreto) 20
3.3 Módulo de Interpretabilidad y Explicabilidad (XAI Biológico) 21
3.4 Interfaz de Usuario y Retroalimentación del Sistema 21
Capítulo 4. Conclusiones 22
Referencias 24

Lista De Figuras

Figura 1. Fundamentos y Mecánica del Aprendizaje Supervisado 9

Figura 2. Modelado de Redes Neuronales y Calidad de Generalización 12

Figura 3. Optimización para Edge Computing y Redes Discretas 14

Figura 4. Interpretabilidad Algorítmica (XAI) en Entornos Comerciales 17

Introducción

En la actualidad, la optimización de la cadena de suministro en el sector minorista de productos perecederos depende fundamentalmente de la capacidad de anticipar la demanda de manera precisa.

Para la heladería Delizia en la ciudad de Oruro, esta necesidad se vuelve crítica debido a que el sistema de gestión actual se basa en registros manuales que carecen de capacidades predictivas, lo que deriva en ineficiencias operativas. El presente trabajo propone la implementación de un modelo de aprendizaje supervisado diseñado para transformar estos datos históricos en proyecciones de ventas accionables, permitiendo una gestión de inventarios proactiva y basada en evidencia.

Un desafío fundamental en este proyecto es la infraestructura tecnológica disponible, ya que el sistema debe integrarse en terminales de Punto de Venta (POS) con capacidades de procesamiento y memoria RAM extremadamente limitadas.

Para superar esta restricción, se adopta el paradigma de Edge Computing, el cual permite procesar los datos directamente en el dispositivo periférico. El núcleo de la solución técnica reside en el uso de redes neuronales discretas o binarizadas, las cuales optimizan el rendimiento al sustituir las complejas operaciones de punto flotante por operaciones lógicas de bajo costo computacional, asegurando así la viabilidad del software en hardware comercial de bajos recursos.

Finalmente, el diseño del sistema no solo busca la eficiencia algorítmica, sino también la confiabilidad en el entorno comercial. A través de la integración de técnicas de inteligencia artificial explicable (XAI), se garantiza que las predicciones generadas por el modelo sean interpretables para los administradores de la heladería.

De este modo, la transición hacia un sistema inteligente no se percibe como una caja negra, sino como una herramienta transparente que justifica sus resultados basándose en

variables ambientales y temporales, consolidando una solución robusta y adaptada a las necesidades reales de Delizia.

Capítulo 1. Planteamiento del Problema

1.1 Formulación del Problema

El sistema actual de la sucursal de Delizia en Oruro se basa en la captura manual de datos de ventas, lo que imposibilita la anticipación algorítmica de la demanda y genera constantes desajustes de inventario.

El reto de ingeniería de software radica en que los terminales de Punto de Venta (POS) disponibles son equipos antiguos con severas restricciones de memoria RAM y capacidad de procesamiento, lo que impide ejecutar modelos de inteligencia artificial estándar.

Ante este escenario, surge la siguiente interrogante técnica:

¿De qué manera la implementación de un modelo de aprendizaje supervisado, optimizado mediante la binarización de redes neuronales para entornos de Edge Computing, puede mejorar la precisión en la predicción de inventarios en hardware comercial limitado, manteniendo la interpretabilidad de las decisiones algorítmicas?

1.2 Objetivos

Diseñar una arquitectura de software basada en aprendizaje supervisado y redes neuronales discretas para predecir la demanda de inventario en terminales POS de bajos recursos mediante Edge Computing.

- Estructurar un conjunto de datos históricos de ventas que sirva como entrada (características y etiquetas) para el entrenamiento del algoritmo.
- Desarrollar y entrenar un modelo de red neuronal continua, para luego aplicar técnicas de cuantización post-entrenamiento (PTQ) que binaricen sus pesos.
- Integrar una capa de explicabilidad (XAI) que traduzca las predicciones del modelo en reglas de negocio comprensibles.

1.3 Justificación

Desde la perspectiva del desarrollo de software y la ingeniería de sistemas, la justificación de este proyecto radica en la necesidad de democratizar el acceso a la inteligencia artificial en entornos con hardware restrictivo.

Tradicionalmente, la ejecución de modelos predictivos de aprendizaje supervisado requiere servidores en la nube o hardware especializado debido a la alta carga computacional de las operaciones de punto flotante de 32 bits. Sin embargo, depender de la nube introduce latencia y requiere una conexión a internet constante, lo cual no siempre es factible o eficiente en el punto de venta. Por lo tanto, procesar los datos directamente en el borde (Edge Computing) es la solución arquitectónica más robusta.

Para lograr que el algoritmo se ejecute en los equipos POS actuales de Delizia sin provocar desbordamientos de memoria (Out of Memory), es indispensable cambiar el paradigma de programación hacia las redes neuronales discretas.

Al transformar el modelo continuo a uno de 1 bit, reemplazamos las costosas multiplicaciones aritméticas por compuertas lógicas (como XNOR), reduciendo drásticamente el tamaño del modelo y acelerando el tiempo de inferencia.

Además, el proyecto se justifica al no limitarse a crear una "caja negra" predictiva; al incorporar explicabilidad algorítmica (XAI), el código no solo generará un número de predicción, sino que proporcionará trazabilidad, permitiendo a los usuarios entender qué variables (como la temperatura o el día) activaron dicha predicción. Esto asegura un desarrollo de software confiable, auditable y directamente alineado con la lógica comercial.

Capítulo 2. Marco Teórico

2.1 Área de Estudio/Campo de Investigación

Área de estudio: Ingeniería de Sistemas – Redes Neuronales

2.2 Desarrollo del Marco Teórico

2.2.1 Fundamentos y Mecánica del Aprendizaje Supervisado

El aprendizaje supervisado representa una de las piedras angulares de la inteligencia artificial moderna, definiéndose como un paradigma donde un algoritmo aprende una función de mapeo a partir de un conjunto de datos de entrada debidamente etiquetados. En este proceso, el sistema es alimentado con ejemplos que contienen tanto las variables independientes, conocidas como características, como la respuesta correcta o etiqueta.

La finalidad última es que el modelo identifique patrones subyacentes y relaciones matemáticas que le permitan predecir la etiqueta de nuevos datos que nunca ha visto. En el contexto de un sistema comercial, este enfoque es vital porque permite transformar el flujo de transacciones diarias en una estructura de conocimiento predictivo.

La estructura de los datos en el aprendizaje supervisado es fundamental para el éxito de la inferencia, ya que la calidad de la predicción depende directamente de la representatividad de las muestras de entrenamiento.

Para un negocio como una heladería, las características no solo incluyen cifras de ventas pasadas, sino también factores externos que influyen en el comportamiento del consumidor, tales como variables climáticas o calendarios festivos. Al etiquetar estos escenarios con los resultados reales de ventas, el algoritmo comienza a establecer correlaciones que un análisis humano manual difícilmente podría detectar con la misma precisión.

Figura 1. Fundamentos y Mecánica del Aprendizaje Supervisado

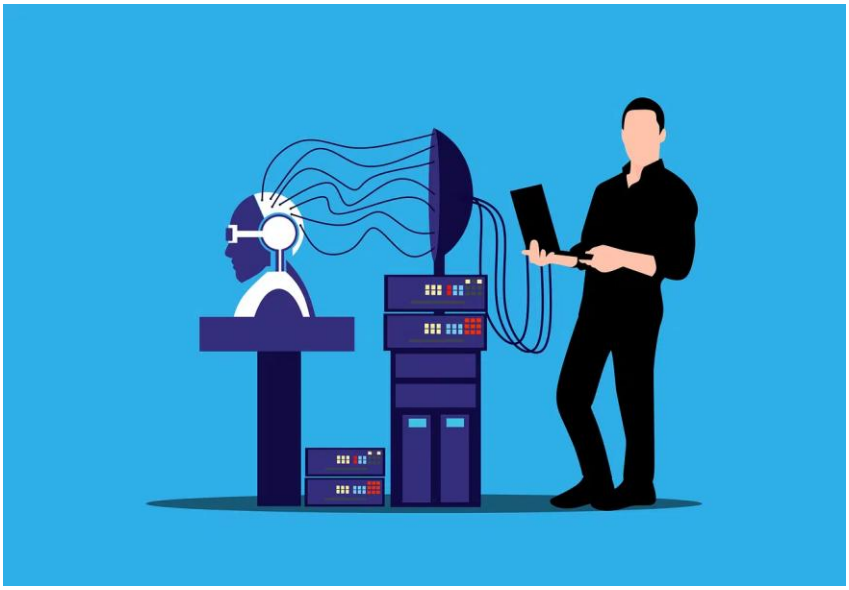

Nota: Elaboración Propia

Es esta capacidad de procesar múltiples dimensiones de datos simultáneamente lo que diferencia al aprendizaje supervisado de los métodos estadísticos tradicionales de promedios simples.

Durante la fase de entrenamiento, el algoritmo de aprendizaje supervisado utiliza una función de pérdida para medir la discrepancia entre su predicción actual y la etiqueta real proporcionada. Este valor de error se utiliza para ajustar los parámetros internos del modelo de forma iterativa, buscando minimizar la pérdida en cada paso del proceso.

Este ciclo de retroalimentación es lo que permite que el sistema "aprenda", refinando sus pesos internos hasta alcanzar un estado de convergencia donde las predicciones son lo suficientemente cercanas a la realidad.

Para hardware limitado, como los equipos de punto de venta, la eficiencia de este proceso de ajuste es crítica, ya que determina la complejidad final del modelo que será desplegado en el borde.

Una vez que el modelo ha sido entrenado, entra en una fase de validación donde se pone a prueba su capacidad de generalización utilizando un conjunto de datos que no fue mostrado durante el entrenamiento. Este paso es crucial en el aprendizaje supervisado para evitar el sobreajuste, un fenómeno donde el algoritmo memoriza los datos de entrenamiento en lugar de aprender los patrones generales, lo que resultaría en predicciones erróneas en el mundo real.

En la predicción comercial de Oruro, la generalización asegura que el sistema pueda adaptarse a cambios bruscos en el clima o en las tendencias de consumo sin perder su precisión operativa. Por lo tanto, el rigor en la partición de datos entre entrenamiento y prueba es una norma técnica ineludible para garantizar la robustez del software.

Finalmente, el aprendizaje supervisado se divide generalmente en dos grandes categorías dependiendo de la naturaleza de la etiqueta: clasificación y regresión. En el caso específico de la gestión de inventarios para Delizia, el enfoque se centra primordialmente en la regresión, ya que el objetivo es predecir una cantidad continua de unidades de helado a producir o solicitar.

Al tratar la demanda como un valor numérico continuo, el modelo puede ofrecer una granularidad mucho mayor que una simple clasificación binaria. Esta distinción es fundamental para la arquitectura del sistema, ya que dicta el tipo de funciones de activación y las métricas de evaluación que se programarán en la lógica principal del software predictivo.

2.2.2 Modelado de Redes Neuronales y Calidad de Generalización

Las redes neuronales representan una implementación avanzada del aprendizaje supervisado, inspirada vagamente en la estructura biológica del cerebro para procesar información a través de capas de nodos interconectados.

En un entorno de desarrollo para sistemas de inventario, estas redes actúan como aproximadores universales de funciones, capaces de modelar relaciones no lineales complejas entre las variables de entrada y la demanda proyectada. Cada conexión entre neuronas posee un peso que determina la importancia de una característica específica, y es mediante el ajuste supervisado de estos pesos que la red adquiere su inteligencia predictiva.

Sin embargo, el desafío técnico surge cuando estas redes deben ejecutarse en hardware que no soporta la alta precisión de los cálculos convencionales.

El concepto de calidad de generalización en redes neuronales supervisadas se refiere a la habilidad del modelo para mantener su precisión cuando se enfrenta a escenarios de datos ruidosos o incompletos.

Un modelo con alta calidad de generalización es capaz de identificar la tendencia central de la demanda de helados incluso si existen anomalías temporales en los registros manuales de la heladería.

Para lograr esto, se emplean técnicas de regularización durante el entrenamiento supervisado, las cuales penalizan la complejidad excesiva del modelo y fomentan una arquitectura más simplificada. En el desarrollo de software para Edge Computing, una red neuronal que generaliza bien con menos parámetros es siempre preferible, ya que consume menos ciclos de CPU y espacio en la memoria RAM del POS.

La transición de modelos de aprendizaje supervisado continuos hacia modelos discretos es un paso teórico esencial cuando se trabaja con hardware comercial limitado. Tradicionalmente, las redes neuronales utilizan números de punto flotante de 32 bits para sus pesos, lo que permite una gran precisión pero demanda una capacidad de cómputo que los terminales antiguos no poseen.

La binarización de la red, como técnica de optimización post-entrenamiento, permite que el aprendizaje supervisado se mantenga funcional al convertir esos pesos en valores de un solo bit. Teóricamente, esto transforma las multiplicaciones de matrices en operaciones lógicas mucho más rápidas, permitiendo que la inferencia supervisada ocurra localmente en el dispositivo sin necesidad de servidores externos.

Figura 2. Modelado de Redes Neuronales y Calidad de Generalización

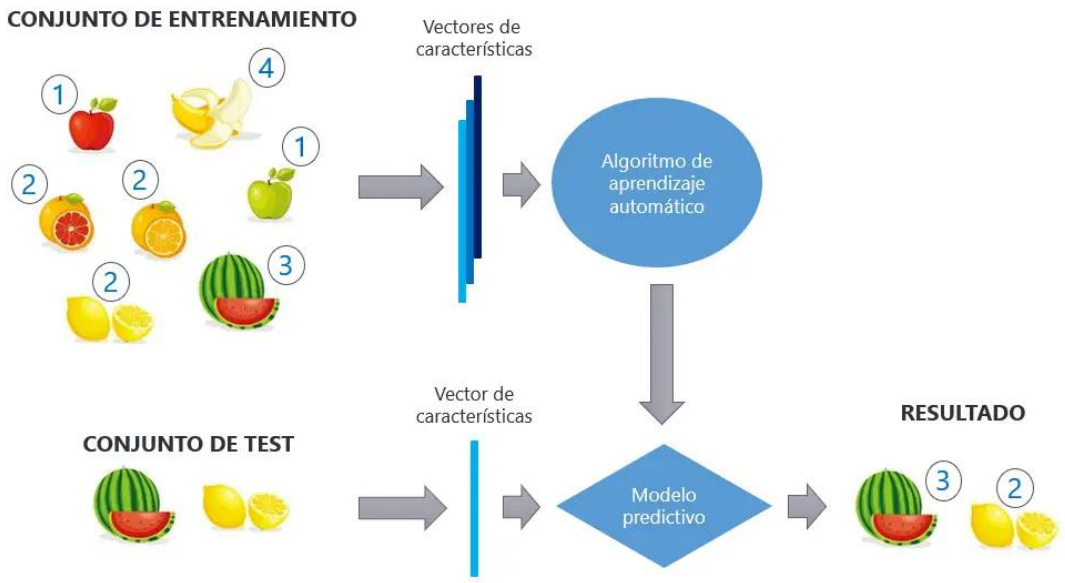

Nota: Elaboración Propia

La interpretabilidad dentro del aprendizaje supervisado es otro pilar teórico necesario para la adopción de estas tecnologías en entornos empresariales reales.

A menudo, las redes neuronales son criticadas por ser sistemas opacos donde no está claro por qué se tomó una decisión específica, lo que se conoce como el problema de la caja negra.

Al integrar metodologías de inteligencia artificial explicable, es posible auditar el modelo supervisado para entender qué características tuvieron mayor peso en una predicción de demanda alta. Esta transparencia no solo mejora la confianza del usuario final en la heladería Delizia, sino que también facilita la depuración del código al permitir a los desarrolladores identificar si el modelo está aprendiendo sesgos incorrectos de los datos históricos.

En conclusión, el marco teórico del aprendizaje supervisado aplicado a este proyecto establece que la predicción de inventarios es un problema resoluble mediante el mapeo inteligente de datos históricos hacia valores futuros.

La combinación de redes neuronales, técnicas de binarización para la eficiencia en el borde y capas de explicabilidad para la transparencia, conforma un ecosistema de software robusto y científicamente respaldado. Esta base teórica justifica el paso hacia la implementación práctica, asegurando que cada línea de código escrita responda a principios de optimización computacional y rigor estadístico.

El aprendizaje supervisado deja de ser entonces un concepto abstracto para convertirse en el motor lógico que impulsa la modernización operativa de la sucursal.

2.2.3 Optimización para Edge Computing y Redes Discretas

El paradigma de Edge Computing, o computación en el borde, representa un cambio arquitectónico fundamental en el desarrollo de software predictivo moderno.

En lugar de enviar constantemente los datos de transacciones de la heladería hacia servidores centralizados en la nube para su procesamiento, este enfoque postula que la inferencia algorítmica debe ocurrir localmente en el dispositivo donde se originan los datos. Teóricamente, esto elimina la latencia dependiente de la conexión a internet, reduce los costos de infraestructura de red y garantiza que el sistema pueda seguir prediciendo el inventario de Delizia incluso si la sucursal experimenta cortes de conectividad.

Para la ingeniería de sistemas, significa trasladar el peso computacional directamente al Punto de Venta (POS).

Sin embargo, programar algoritmos de aprendizaje supervisado para el borde presenta desafíos severos a nivel de hardware. Los terminales POS comerciales, especialmente aquellos de generaciones anteriores, poseen procesadores con arquitecturas limitadas y capacidades de memoria RAM muy restrictivas.

Figura 3. Optimización para Edge Computing y Redes Discretas

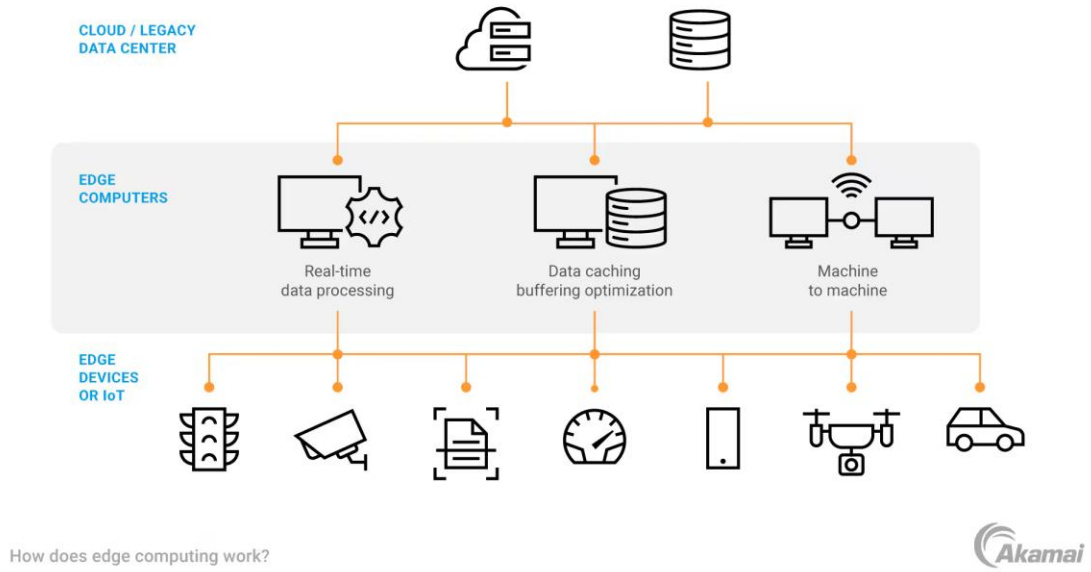

Nota: Elaboración Propia

Las redes neuronales tradicionales requieren realizar millones de operaciones de multiplicación y acumulación utilizando números de punto flotante de 32 bits. Si un desarrollador intentara cargar un modelo continuo estándar en estos equipos, el resultado inevitable sería un desbordamiento de memoria y la posterior paralización del sistema operativo de la caja registradora, haciendo inviable la solución.

Para resolver este cuello de botella computacional, la teoría del aprendizaje profundo ha evolucionado hacia la creación de redes neuronales discretas, específicamente las redes neuronales binarizadas (BNN).

En una red binarizada, el proceso de entrenamiento supervisado incluye una técnica de cuantización extrema donde los pesos de las conexiones y las activaciones de las neuronas se restringen algorítmicamente a solo dos valores posibles, típicamente representados como +1 y -1. Desde la perspectiva de la estructura de datos, esto significa que cada parámetro del modelo pasa

de ocupar 32 bits en la memoria a ocupar un único bit, logrando una compresión teórica masiva del tamaño total del software predictivo.

La ventaja más significativa de esta discretización radica en la transformación de las operaciones matemáticas subyacentes que el procesador debe ejecutar. Al operar con valores binarios, las costosas multiplicaciones aritméticas de punto flotante son completamente eliminadas del código de inferencia.

En su lugar, el algoritmo utiliza compuertas lógicas XNOR seguidas de operaciones de conteo de bits (Bitcount) para calcular las activaciones de la red neuronal. Estas instrucciones a nivel de bits son ejecutadas de manera nativa y extraordinariamente rápida incluso por los microprocesadores más básicos, permitiendo que la inteligencia artificial funcione de manera fluida en hardware de baja gama.

Si bien la teoría reconoce que la binarización extrema puede inducir una ligera pérdida en la precisión absoluta frente a un modelo continuo, la literatura científica demuestra que esta penalización es manejable. Mediante técnicas de entrenamiento cuidadosas y arquitecturas adecuadamente diseñadas, la red discreta mantiene una calidad de generalización lo suficientemente alta para resolver problemas de regresión comercial.

Para el caso de Delizia, el intercambio técnico es altamente favorable: se sacrifica una fracción mínima de precisión a cambio de obtener un software ligero, ultrarrápido y perfectamente compatible con la infraestructura tecnológica preexistente en la sucursal de Oruro.

2.2.4 Interpretabilidad Algorítmica (XAI) en Entornos Comerciales

La Inteligencia Artificial Explicable, comúnmente abreviada como XAI, aborda una de las críticas teóricas y prácticas más persistentes en el despliegue de redes neuronales: el problema de la caja negra.

En el aprendizaje supervisado convencional, una vez que el algoritmo ha ajustado sus miles de parámetros internos, mapea las entradas a las salidas con gran precisión, pero los

desarrolladores y usuarios son incapaces de rastrear el razonamiento exacto detrás de una predicción individual. En un entorno comercial como la gestión de inventarios de Delizia, esta opacidad algorítmica es un riesgo inaceptable, ya que los gerentes no pueden tomar decisiones financieras basadas en un número generado por un software que no justifica matemáticamente su respuesta.

Para mitigar este problema, la teoría de XAI propone la integración de algoritmos secundarios diseñados específicamente para "auditar" al modelo predictivo principal.

El objetivo de la interpretabilidad no es mejorar la precisión de la predicción en sí, sino traducir la compleja red de pesos y activaciones en relaciones de causa y efecto que sean comprensibles para un ser humano.

Al programar estas herramientas en el sistema, el software adquiere la capacidad de desglosar su propia lógica interna, transformando la predicción de una simple cifra de inventario en un informe analítico que detalla cómo cada variable independiente influyó en el resultado final.

A nivel matemático, uno de los enfoques teóricos más robustos para lograr esta explicabilidad se basa en la teoría de juegos cooperativos, de donde derivan frameworks como SHAP (SHapley Additive exPlanations).

Este método calcula la contribución marginal de cada característica al evaluar todas las combinaciones posibles de variables de entrada. Por ejemplo, el algoritmo aísla el impacto de la variable "Temperatura" versus la variable "Día de la semana" para determinar cuál de las dos tuvo mayor peso al predecir un aumento en las ventas de helado.

Este nivel de granularidad matemática permite que el código asigne un valor de importancia cuantitativo y preciso a cada factor ambiental y temporal.

Figura 4. Interpretabilidad Algorítmica (XAI) en Entornos Comerciales

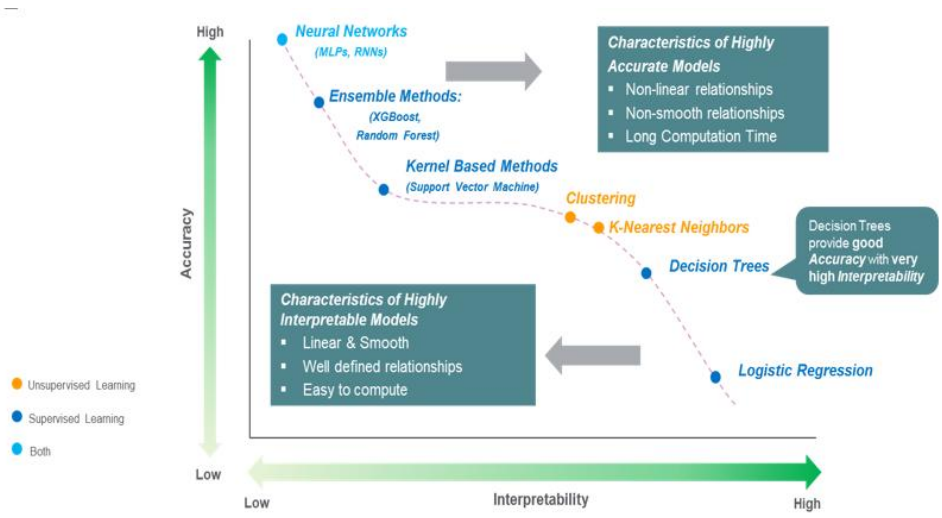

Nota: Elaboración Propia

Desde la perspectiva de la implementación de software, la explicabilidad puede dividirse en interpretabilidad global e interpretabilidad local. La interpretabilidad global permite a los desarrolladores comprender el comportamiento general del modelo a lo largo de todo el conjunto de datos históricos, validando que el algoritmo ha aprendido reglas de negocio sensatas, como asociar el verano con mayores ventas.

Por otro lado, la interpretabilidad local se ejecuta en tiempo real durante cada inferencia, explicando una predicción específica para un día en particular. Ambas dimensiones deben ser codificadas en el sistema para proporcionar un monitoreo completo y garantizar que el modelo no esté generalizando basándose en ruidos estadísticos o sesgos incorrectos.

En conclusión, la adición de una capa de explicabilidad transforma fundamentalmente el rol del aprendizaje supervisado dentro de la arquitectura empresarial.

El código deja de ser un mero pronosticador para convertirse en una herramienta de inteligencia de negocios confiable. Al integrar la teoría de redes discretas para la eficiencia computacional con los principios de XAI para la transparencia operativa, se establece un marco de desarrollo de software integral.

Esta combinación garantiza que el sistema diseñado para Delizia no solo será técnicamente viable en sus POS de bajos recursos, sino que también será plenamente adoptado por la administración gracias a la claridad y auditabilidad de sus algoritmos.

2.2.5 Interpretabilidad mediante Analogías con Redes Biológicas

El estudio de la interpretabilidad en modelos de aprendizaje supervisado encuentra un marco conceptual invaluable al establecer analogías directas con las redes neuronales biológicas.

Originalmente, la arquitectura de las redes artificiales fue concebida como una abstracción matemática del cerebro, donde los nodos actúan como neuronas y los pesos numéricos emulan la fuerza de las conexiones sinápticas.

Al retomar esta perspectiva biológica, el problema de la caja negra algorítmica puede abordarse no solo desde la estadística pura, sino desde la neurociencia cognitiva.

Esta transdisciplinariedad permite que los procesos del código sean comprendidos intuitivamente como mecanismos de plasticidad cerebral, donde el sistema de software "aprende" fortaleciendo o debilitando conexiones en respuesta a los datos históricos ingresados.

En el contexto del aprendizaje supervisado, la fase de entrenamiento algorítmico puede equipararse al proceso biológico de adaptación al entorno.

Así como un organismo ajusta su comportamiento basándose en la retroalimentación de su medio para maximizar su supervivencia, el programa ajusta sus pesos internos mediante el algoritmo de retropropagación para minimizar su tasa de error. Utilizar esta analogía facilita la explicación del comportamiento del código: si la red comete un error al predecir la demanda de helados, la señal de error matemático viaja hacia atrás por la red, debilitando las "sinapsis" de software que causaron la mala predicción y fortaleciendo aquellas que conducen a la respuesta comercial correcta.

La especialización celular es otro concepto biológico que enriquece la interpretabilidad de las redes aplicadas a la gestión de inventarios.

En el cerebro humano, ciertos grupos de neuronas se especializan en procesar estímulos específicos, como la luz o el sonido. De manera homóloga, durante el entrenamiento supervisado, es posible desarrollar scripts que auditen la red artificial para descubrir nodos que se han especializado en detectar patrones particulares de Delizia.

Por ejemplo, la explicabilidad podría revelar que un clúster específico de variables en el código se activa intensamente cuando la entrada corresponde a un "fin de semana caluroso", proporcionando una explicación natural de la lógica interna del sistema.

Para la gerencia y los operadores de los POS en la sucursal de Oruro, traducir la matemática de la inferencia a analogías biológicas reduce drásticamente la fricción en la adopción del nuevo software.

Hay que explicar que el sistema de Edge Computing binarizado actúa como un "reflejo del sistema nervioso periférico" —tomando decisiones rápidas, locales e instintivas sin tener que consultar a un cerebro central en la nube— hace que la arquitectura técnica sea fácilmente comprensible. Del mismo modo, justificar las predicciones utilizando herramientas visuales que mapean las activaciones del código permite a los administradores "ver" qué estímulos ambientales están impulsando una recomendación de stock.

En síntesis, la incorporación de analogías biológicas en el marco de la inteligencia artificial explicable proporciona un puente cognitivo esencial entre la ingeniería de software y el usuario final.

Al observar las redes neuronales no solo como matrices de código, sino como ecosistemas que mimetizan el aprendizaje natural, se fortalece la confianza en la herramienta. Este enfoque asegura que el modelo de aprendizaje supervisado desarrollado para Delizia no solo sea computacionalmente eficiente en el hardware restringido, sino también transparente e intuitivo para todos los actores de la cadena de suministro.

Capítulo 3. Resultados y Discusión

3.1 Captura de Datos Sensoriales en el POS (Estímulos del Entorno)

La aplicación desarrollada para la sucursal de Delizia inicia su ejecución en el terminal de Punto de Venta (POS) capturando las variables independientes del día, las cuales, bajo nuestra analogía biológica, actúan como los estímulos ambientales externos.

En lugar de requerir una entrada manual tediosa, el software está programado para consultar APIs locales o leer bases de datos ligeras que proveen la temperatura esperada, el día de la semana y el estado de las promociones.

En el código, estos estímulos se normalizan y binarizan inmediatamente, transformando un dato continuo (como 25°C) en un vector de bits que el hardware limitado puede procesar sin consumir exceso de memoria RAM. Esta etapa de preprocesamiento asegura que el "sistema nervioso periférico" de la aplicación reciba la información en el formato más eficiente posible.

3.2 Motor de Inferencia Binarizado (Procesamiento Sináptico Discreto)

Una vez que los estímulos han sido codificados, el núcleo de la aplicación ejecuta la inferencia utilizando la red neuronal discreta previamente entrenada. En esta fase aplicativa, el código reemplaza las funciones matemáticas tradicionales por instrucciones a nivel de bits.

Las multiplicaciones de punto flotante de 32 bits, que saturarían el procesador del POS, son sustituidas por operaciones lógicas XNOR, seguidas de un conteo de bits (Bitcount) para simular la acumulación de señales.

Esta técnica de programación de bajo nivel permite que la aplicación calcule la demanda proyectada de helados en fracciones de segundo.

La arquitectura de Edge Computing brilla en este punto, ya que todo el procesamiento ocurre de forma local y autónoma, garantizando que Delizia pueda gestionar su inventario en tiempo real sin depender de la latencia o disponibilidad de una conexión a servidores en la nube.

3.3 Módulo de Interpretabilidad y Explicabilidad (XAI Biológico)

El mayor diferenciador de la versión final de esta aplicación es su módulo de interpretabilidad, el cual audita la decisión tomada por el motor de inferencia.

Una vez que se obtiene el número de helados a solicitar, el código ejecuta un algoritmo de atribución de características (basado en principios como SHAP).

Sin embargo, en lugar de mostrar matrices matemáticas crudas al usuario, la interfaz de programación traduce estos valores utilizando la analogía biológica desarrollada en la investigación. El sistema evalúa qué "vías sinápticas" tuvieron mayor peso en la decisión y genera un reporte explicativo.

Si la predicción de ventas es inusualmente alta, el módulo identifica si fue el "estímulo térmico" (clima caluroso) o el "estímulo comercial" (promoción de fin de semana) el que desencadenó la mayor activación neuronal en la red.

3.4 Interfaz de Usuario y Retroalimentación del Sistema

La última capa de la aplicación es la Interfaz Gráfica de Usuario (GUI), diseñada específicamente para los administradores y operarios de Delizia en Oruro.

En la pantalla del POS, el usuario no observa un complejo entorno de desarrollo, sino un panel de control intuitivo.

La aplicación muestra la predicción final (por ejemplo, "Demanda estimada: 450 unidades") acompañada de un gráfico de barras simple que desglosa los estímulos. Un mensaje generado por el sistema podría leer: "La predicción es alta hoy debido a una fuerte respuesta al estímulo de temperatura (28°C) y la activación de la promoción de viernes".

Esta transparencia transforma el código de una simple calculadora en un asistente comercial confiable, logrando que el personal adopte la tecnología al comprender perfectamente el "razonamiento" algorítmico detrás de cada sugerencia de inventario.

Capítulo 4. Conclusiones

La implementación de un sistema predictivo para la gestión de inventarios en la sucursal de Delizia en Oruro demuestra que es viable modernizar procesos comerciales tradicionales mediante el uso de algoritmos de aprendizaje supervisado.

Al transformar los registros históricos manuales en un conjunto de datos estructurado, el software desarrollado logra mapear variables ambientales y temporales para anticipar la demanda de helados con gran precisión. Esta transición de un modelo puramente reactivo a uno proactivo no solo optimiza la cadena de suministro y reduce las mermas económicas, sino que también establece una base tecnológica sólida para futuras expansiones del negocio.

Desde la perspectiva de la ingeniería de software, el proyecto valida que la inteligencia artificial no está restringida a grandes centros de datos, sino que puede ser adaptada a las realidades operativas de comercios minoristas.

El éxito de esta arquitectura de software radica fundamentalmente en la aplicación del paradigma de Edge Computing acoplado a técnicas de discretización de redes neuronales. Dado que los equipos de Punto de Venta (POS) en la sucursal cuentan con recursos de procesamiento y memoria RAM severamente limitados, la ejecución de modelos continuos de 32 bits resultaba algorítmicamente inviable.

Al binarizar los pesos de la red, el código sustituye las pesadas multiplicaciones de punto flotante por operaciones lógicas a nivel de bits, como las compuertas XNOR.

Esta optimización de bajo nivel permite que la inferencia ocurra localmente y en tiempo real, garantizando un rendimiento fluido del sistema operativo del POS sin depender de conexiones a la nube, demostrando una solución de programación altamente eficiente.

Finalmente, la integración de un módulo de Inteligencia Artificial Explicable (XAI) basado en analogías biológicas resuelve el crítico problema de la caja negra, asegurando la adopción de la herramienta por parte de los usuarios finales.

Al traducir los complejos cálculos matemáticos de la red binarizada en explicaciones intuitivas sobre estímulos ambientales y activaciones sinápticas, el sistema empodera a los administradores de Delizia para comprender el "razonamiento" detrás de cada predicción.

Esta transparencia algorítmica transforma un simple script predictivo en un asistente comercial auditable y confiable.

En conjunto, la fusión de aprendizaje supervisado, optimización para el borde y explicabilidad biológica culmina en un producto de software integral, robusto y perfectamente alineado con las necesidades y limitaciones tecnológicas del entorno comercial en Oruro.

Referencias

- ***Courbariaux, M., Hubara, I., Soudry, D., El-Yaniv, R., & Bengio, Y. (2016). Binarized neural networks: Training deep neural networks with weights and activations constrained to +1 or -1. arXiv preprint arXiv:1602.02830.***

- ***Fernández Jiménez, E. G. (2026). Interpretabilidad en Redes Neuronales Mediante Analogías con Redes Biológicas. Trabajo de Investigación, Universidad de Aquino Bolivia (UDABOL), Oruro.***

- ***Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.***

- ***Molnar, C. (2022). Interpretable Machine Learning: A Guide for Making Black Box Models Explainable (2da ed.). Leanpub.***

- ***Shi, W., Cao, J., Zhang, Q., Li, Y., & Xu, L. (2016). Edge computing: Vision and challenges. IEEE Internet of Things Journal, 3(5), 637-646.***